Projet de statistique appliquée, Ensae

IP PARIS

Word-Embedding et sentiments des ménages avec Twitter

Kim Antunez, Romain Lesauvage et Alain Quartier-la-Tente

11/06/2020

Ensae — 2019-2020

Introduction (1/2)

- modèle de NLP développé par Google (Mikolov et al (2013))
- **objectif** = *word-embedding* : donner une représentation vectorielle aux mots

Introduction (1/2)

- modèle de NLP développé par Google (Mikolov et al (2013))
- **objectif** = *word-embedding* : donner une représentation vectorielle aux mots
-  réseau de neurones à deux couches permettant de traiter des grandes bases de données

Introduction (1/2)

- modèle de NLP développé par Google (Mikolov et al (2013))
- **objectif** = *word-embedding* : donner une représentation vectorielle aux mots
-  réseau de neurones à deux couches permettant de traiter des grandes bases de données
- les mots avec le même contexte ont des représentations vectorielles proches :

$$\overrightarrow{Paris} - \overrightarrow{France} + \overrightarrow{Italie} = \overrightarrow{Rome}$$

Introduction (2/2)

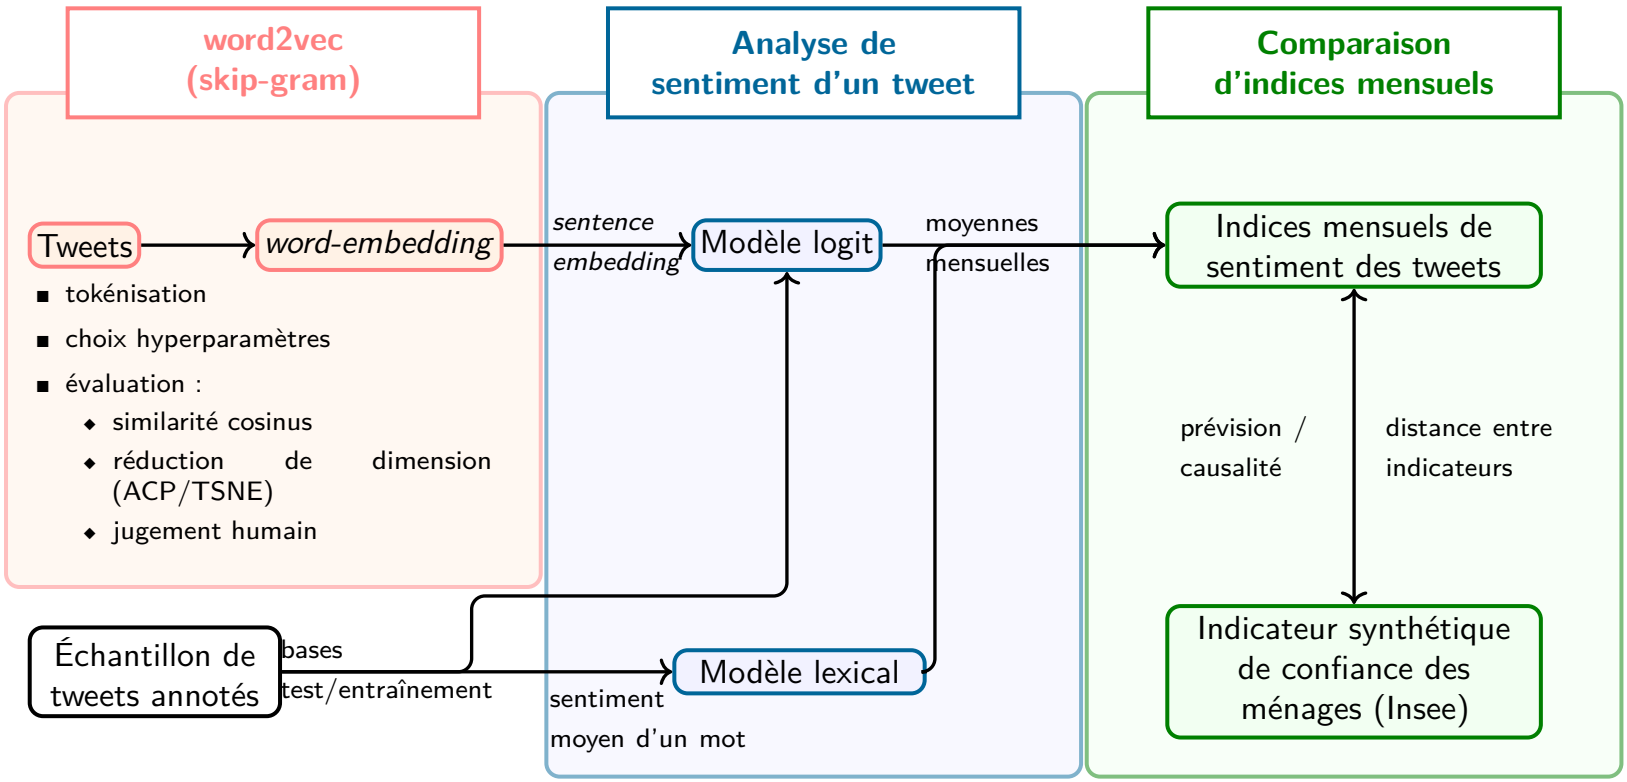

Sommaire

L'approche Skip-gram

Approche retenue : Skip-gram

- étant donné un mot *focus* quels pourraient être ses voisins (*contextes*) ?
- les *contextes* dépendent d'un paramètre : la *fenêtre* w

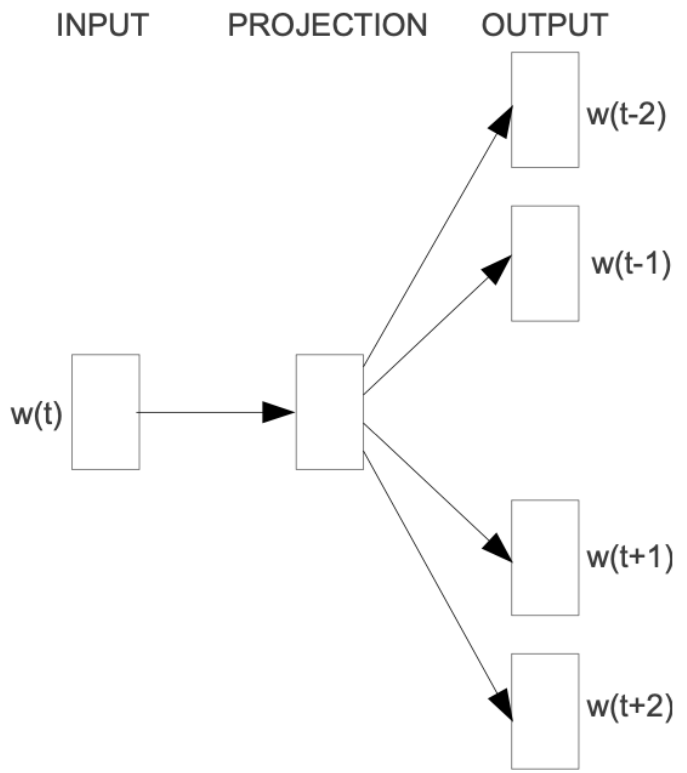

L'approche Skip-gram

Approche retenue : Skip-gram

- étant donné un mot *focus* quels pourraient être ses voisins (*contextes*) ?
- les *contextes* dépendent d'un paramètre : la *fenêtre* w

Exemple $w = 2$:

> “*Espérons que la présentation sous Teams se passe bien*”

Voisins(`passe`) = `[Teams, se, bien]`

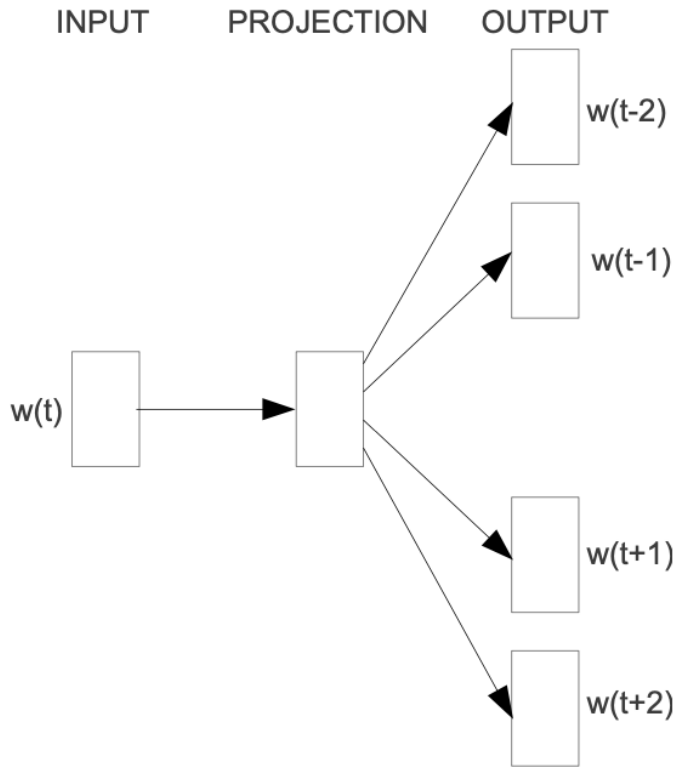

L'approche Skip-gram

Approche retenue : Skip-gram
- étant donné un mot *focus* quels pourraient être ses voisins (*contextes*) ?
- les *contextes* dépendent d'un paramètre : la *fenêtre* w

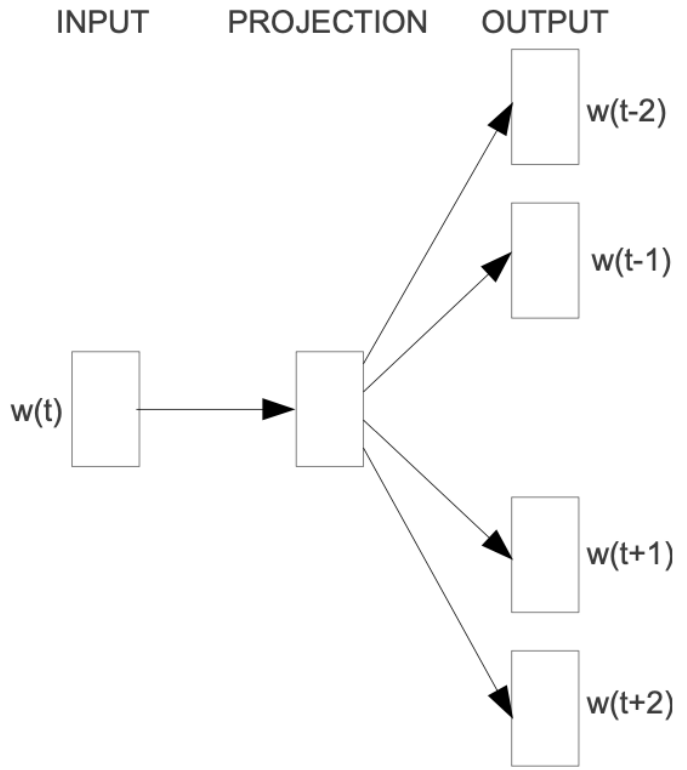

Exemple $w = 2$:

> “*Espérons que la présentation sous Teams se passe bien*”

Voisins(`passe`) = `[Teams, se, bien]`

Approche CBOW (non retenue) : objectif inverse

Construction de la base d'entraînement (1/2)

À partir de couples `[focus, contexte]`, on met itérativement à jour deux matrices W_e et W_s. Représentation vectorielle finale :

$$\text{vocabulaire} \left\{ \quad \frac{W_e + W_s}{2} = \underbrace{\begin{pmatrix} \text{représentation mot 1} \\ \\ \text{représentation mot } n \end{pmatrix}}_{\text{dimension } dim} \right.$$

Construction de la base d'entraînement (1/2)

À partir de couples `[focus, contexte]`, on met itérativement à jour deux matrices W_e et W_s. Représentation vectorielle finale :

$$\text{vocabulaire} \left\{ \quad \frac{W_e + W_s}{2} = \underbrace{\begin{pmatrix} \text{représentation mot 1} \\ \\ \text{représentation mot } n \end{pmatrix}}_{\text{dimension } dim} \right.$$

Pour chaque phrase on :

- supprime la ponctuation, met tout en minuscule
- effectue un sous-échantillonnage des mots (*subsampling*)
- tire au hasard un mot *focus* et un mot *contexte* associé

➔ on parcourt la base *epochs* fois

Construction de la base d'entraînement (2/2)

Exemple avec $w = 2$:

> “*Espérons que la présentation sous Teams se passe bien ! ! !*”

– on supprime la ponctuation, met tout en minuscule
➔ `[espérons, que, la, présentation, sous, teams, se, passe, bien]`

Construction de la base d'entraînement (2/2)

Exemple avec $w = 2$:

> “*Espérons que la présentation sous Teams se passe bien ! ! !*”

- on supprime la ponctuation, met tout en minuscule
  ➔ `[espérons, que, la, présentation, sous, teams, se, passe, bien]`
- on effectue un sous-échantillonnage des mots (*subsampling*)
  ➔ `[espérons, X, X, présentation, X, teams, se, passe, X]`

Construction de la base d'entraînement (2/2)

Exemple avec $w = 2$:

> “*Espérons que la présentation sous Teams se passe bien ! ! !*”

- on supprime la ponctuation, met tout en minuscule
  ➔ `[espérons, que, la, présentation, sous, teams, se, passe, bien]`
- on effectue un sous-échantillonnage des mots (*subsampling*)
  ➔ `[espérons, X, X, présentation, X, teams, se, passe, X]`
- on tire au hasard un mot *focus* et un mot *contexte* associé
  ➔ On tire un mot au hasard parmi `[présentation, teams]`, `[teams, présentation]`, `[teams, se]`, `[teams, passe]`, `[se, teams]`, ...

Actualisation de W_e et W_s

Pour chaque couple `[focus, contexte]` : actualisation de W_e et W_s par descente de gradient :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_\theta Loss(\theta^{(t)})$$

η *taux d'apprentissage* et $Loss(\theta)$ fonction de perte

Actualisation de W_e et W_s

Pour chaque couple `[focus, contexte]` : actualisation de W_e et W_s par descente de gradient :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_\theta Loss(\theta^{(t)})$$

η *taux d'apprentissage* et $Loss(\theta)$ fonction de perte

Deux approches :

1. *softmax* : pour un mot `focus` on estime la probabilité que les autres mots soient voisins (classification multiclasse)

$$\mathbb{P}(w_{contexte} | w_{focus}) = ?$$

Actualisation de W_e et W_s

Pour chaque couple `[focus, contexte]` : actualisation de W_e et W_s par descente de gradient :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_\theta Loss(\theta^{(t)})$$

η *taux d'apprentissage* et $Loss(\theta)$ fonction de perte

Deux approches :

1. *softmax* : pour un mot `focus` on estime la probabilité que les autres mots soient voisins (classification multiclasse)

$$\mathbb{P}(w_{contexte}|w_{focus}) = ?$$

2. *negative sampling* : pour chaque couple `[contexte, mot2]` on estime la probabilité que `mot2` soit voisin de `contexte` (classification binaire)

$$\mathbb{P}(D = 1|w_{focus}, w_{mot2}) = ?$$

softmax et *negative sampling*

Pour chaque couple `[focus, contexte]` :

1. *softmax* : on maximise

$$\mathbb{P}(w_{contexte}|w_{focus}) = \frac{\exp(W_{e,w_{focus}} \times {}^{t}W_{s,w_{contexte}})}{\sum_{i=1}^{n} \exp(W_{e,w_{focus}} \times {}^{t}W_{s,w_i})}$$


Complexité : $\mathcal{O}(n)$ et $n \simeq 70\ 000$

softmax et *negative sampling*

Pour chaque couple `[focus, contexte]` :

1. *softmax* : on maximise

$$\mathbb{P}(w_{contexte}|w_{focus}) = \frac{\exp(W_{e,w_{focus}} \times {}^tW_{s,w_{contexte}})}{\sum_{i=1}^{n} \exp(W_{e,w_{focus}} \times {}^tW_{s,w_i})}$$


Complexité : $\mathcal{O}(n)$ et $n \simeq 70\ 000$

2. *negative sampling* : on tire $K = 5$ mots "négatifs" $(w_{neg,i})_{i=1..K}$ a priori non liés à `[focus, contexte]`
   On maximise $\mathbb{P}(D = 1|w_{focus}, w_{contexte})$ et $\mathbb{P}(D = 0|w_{focus}, w_{neg,i})$

$$\begin{cases} \mathbb{P}(D = 1|w_{focus}, w_{contexte}) & = \sigma(W_{e,w_{focus}} {}^tW_{s,w_{contexte}}) \\ \mathbb{P}(D = 0|w_{focus}, w_{neg,i}) & = \sigma(-W_{e,w_{focus}} {}^tW_{s,w_{neg,i}}) \\ \sigma(x) = \frac{1}{1+\exp()} \end{cases}$$


Complexité : $\mathcal{O}(K)$

Sommaire

Comment évaluer le modèle ?

Les vecteurs-mots sont de grande dimension : comment juger de leur qualité et de leurs proximités ?

- **Similarité cosinus** : distance entre vecteurs-mots.
- **ACP et t-SNE** : réduire la dimension et analyser les proximités.
- **Jugement humain** : corrélations entre les proximités de nos vecteurs-mots et une base de proximités de mots construites par le jugement d'individus

Évaluation sur un corpus fictif (1/2)

Idée : construire un corpus fictif pour lesquels on connaît le résultat attendu.

En pratique :

- On génère 10 groupes de mots composés d'un couple de référence et de 10 autres mots contexte.
- On construit 10 000 phrases en tirant au hasard :
  - 1 des groupes de mots ;
  - 1 des 2 mots « références » du groupe ;
  - 5 mots contextes ;
  - 3 mots bruits parmi une liste de 100 mots.
- On mélange les 9 mots de chaque phrase.

Évaluation sur un corpus fictif (2/2)

mot	similarité cosinus avec « grand »
longueur	0,982
petit	0,981
s	0,979
⋮	⋮
susiens	$-0,735$
allates	$-0,784$

mot	similarité cosinus avec « petit »
taille	0,987
longueur	0,983
grand	0,981
⋮	⋮
alesiez	$-0,745$
allates	$-0,810$

Paramètres utilisés : ep = 50 / lr = 0,01 / w = 5 / dim = 10.

➔ implémentation semble validée (résultats conformes aux attendus)

Déterminer les hyperparamètres

- *Word2vec* se base sur différents choix d'hyperparamètres :
  - taille de la fenêtre (w)
  - nombre d'epochs (ep)
  - taux d'apprentissage (lr)
  - dimension des *word-embeddings* (dim)

- Détermination empirique des hyperparamètres :
  - corrélation de Spearman entre nos vecteurs-mots et une base de jugement humain
  - chronophage (il faut relancer le modèle à chaque fois).

➔ Utilisation complémentaire de `Gensim` puis validation avec notre implémentation.

Exemple : epochs, fenêtre et taux d'apprentissage

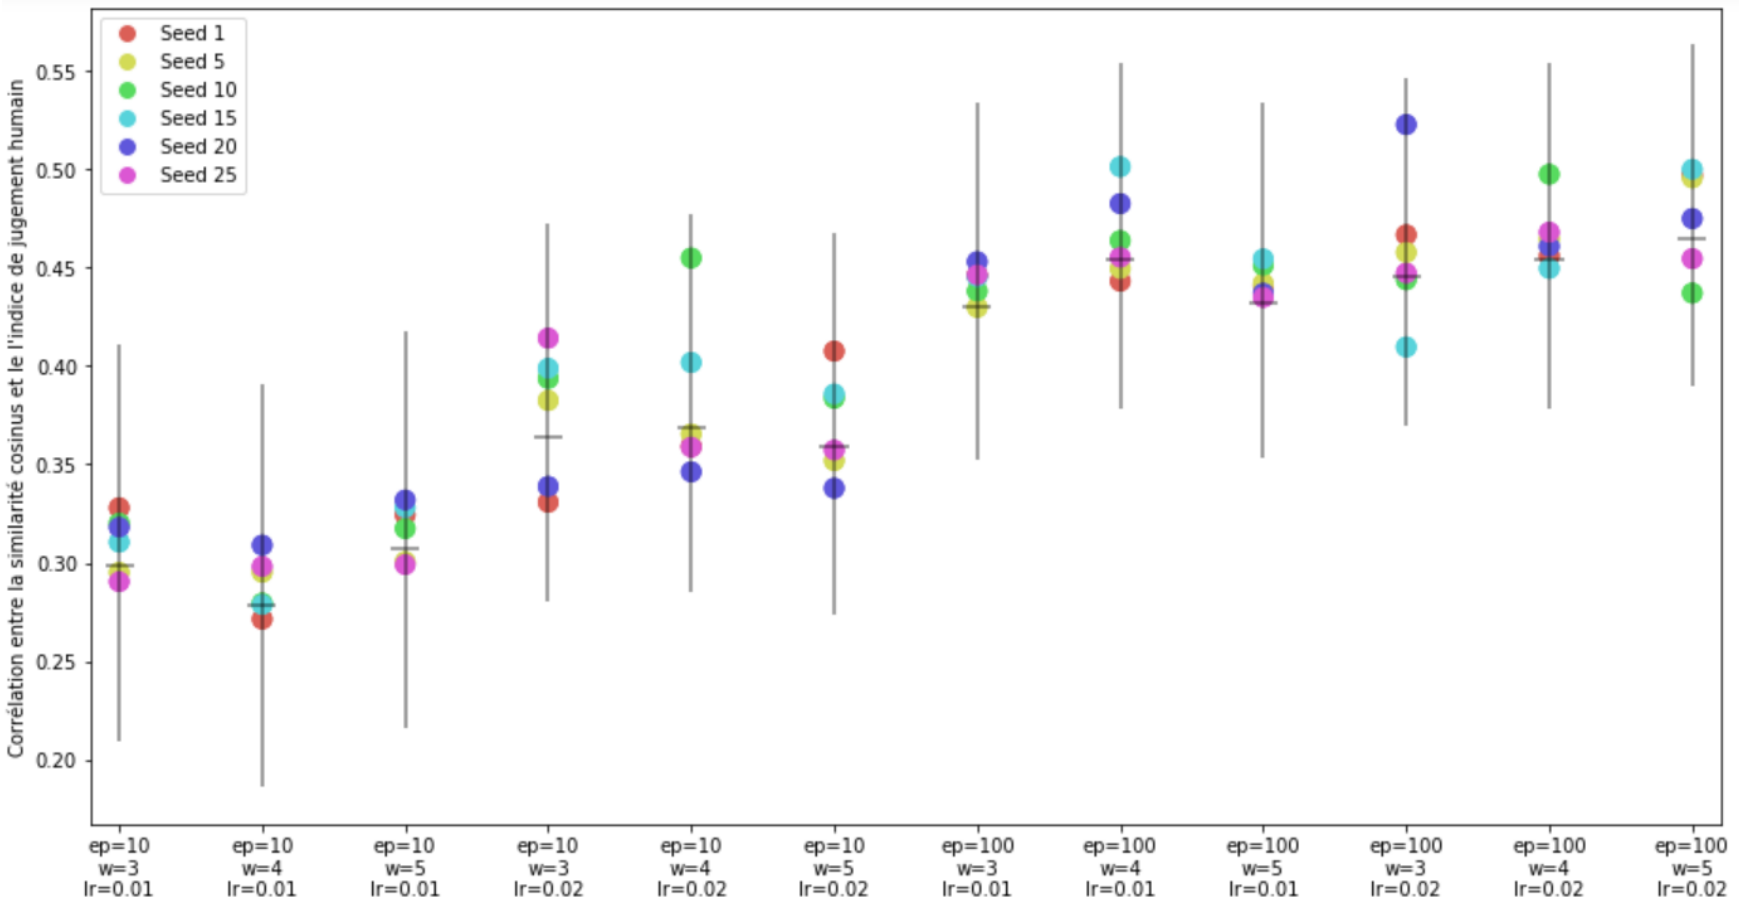

Paramètre utilisé : dim = 50

Valeurs retenues pour les hyperparamètres

- **Nombre d'epochs** : qualité des résultats croît avec le nombre d'epochs

  ➔ **ep = 100**.

- **Taille de fenêtre** : capte des informations sémantiques différentes selon sa valeur

  ➔ **w = 4**.

- **Taux d'apprentissage** : 0,02 donne de meilleurs résultats

  ➔ **lr = 0,02**.

- **Dimension** : qualité des résultats croît avec la dimension jusqu'à 300 puis décroît. Peu de différences entre 100 et 300.

  ➔ **dim = 100**.

Évaluation sur le corpus de tweets (1/2)

« Notre » modèle

Spearman : 0,57 (p-v : 4,1 %)

➔ **bons** résultats

bonjour *(669)*	**femme** *(264)*	**1** *(765)*	**samedi** *(203)*
😘 (0,59)	quelle (0,49)	5 (0,55)	soir (0,57)
😊 (0,59)	cette (0,46)	mois (0,51)	vivement (0,51)
merci (0,54)	une (0,44)	10 (0,49)	demain (0,50)
nuit (0,48)	vie (0,44)	2 (0,48)	end (0,48)
bisous (0,47)	grippe (0,44)	top (0,48)	weekend (0,47)
bonne (0,47)	belle (0,43)	depuis (0,47)	matin (0,45)
☺️ (0,46)	ma (0,43)	saison (0,46)	jeudi (0,45)
vous (0,46)	magnifique (0,43)	ans (0,44)	prochain (0,43)
plaisir (0,44)	nouvelle (0,43)	jours (0,43)	week (0,43)
allez (0,43)	vidéo (0,39)	3 (0,43)	🎉 (0,42)

ep = 80 / w = 4 / lr = 0,02 / dim = 100 / base : 100 000 tweets

Évaluation sur le corpus de tweets (1/2)

« Notre » modèle

Spearman : 0,57 (p-v : 4,1 %)

➔ **bons** résultats

bonjour *(669)*	**femme** *(264)*	**1** *(765)*	**samedi** *(203)*
😘 (0,59)	quelle (0,49)	5 (0,55)	soir (0,57)
😊 (0,59)	cette (0,46)	mois (0,51)	vivement (0,51)
merci (0,54)	une (0,44)	10 (0,49)	demain (0,50)
nuit (0,48)	vie (0,44)	2 (0,48)	end (0,48)
bisous (0,47)	grippe (0,44)	top (0,48)	weekend (0,47)
bonne (0,47)	belle (0,43)	depuis (0,47)	matin (0,45)
☺️ (0,46)	ma (0,43)	saison (0,46)	jeudi (0,45)
vous (0,46)	magnifique (0,43)	ans (0,44)	prochain (0,43)
plaisir (0,44)	nouvelle (0,43)	jours (0,43)	week (0,43)
allez (0,43)	vidéo (0,39)	3 (0,43)	🎉 (0,42)

ep = 80 / w = 4 / lr = 0,02 / dim = 100 / base : 100 000 tweets

Modèle `Gensim`

Spearman : 0,50 (p-v : 0,0 %)

➔ **très bons** résultats

bonjour *(17 043)*	**femme** *(6 177)*	**1** *(21 055)*	**samedi** *(4 917)*
bonsoir (0,85)	fille (0,86)	2 (0,65)	vendredi (0,88)
bjr (0,75)	copine (0,74)	3 (0,64)	jeudi (0,86)
hello (0,71)	meuf (0,71)	6 (0,63)	lundi (0,83)
salut (0,66)	demoiselle (0,66)	4 (0,62)	mercredi (0,83)
coucou (0,55)	nana (0,66)	7 (0,60)	dimanche (0,83)
transmets (0,49)	nièce (0,66)	5 (0,58)	mardi (0,76)
désagrément (0,48)	sœur (0,65)	9 (0,58)	demain (0,72)
avezvous (0,48)	barbe (0,65)	8 (0,56)	barathon (0,56)
bettembourg (0,48)	maman (0,64)	1e (0,55)	22h45 (0,55)
hey (0,47)	princesse (0,64)	34 (0,53)	20h (0,54)

ep = 100 / w = 4 / lr = 0,02 / dim = 100 / base : ensemble des tweets

10 plus proches voisins par similarité cosinus

Évaluation sur le corpus de tweets (2/2)

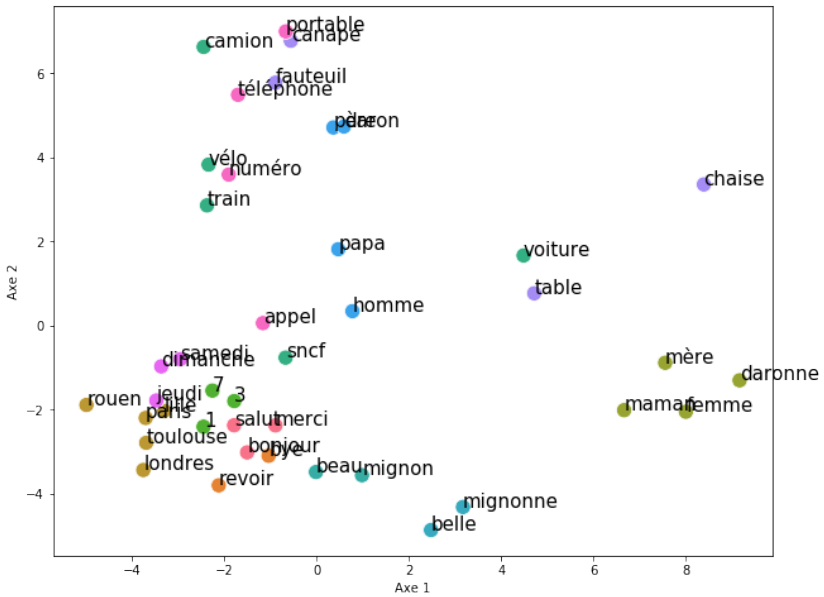

ACP sur un corpus réduit de mots.

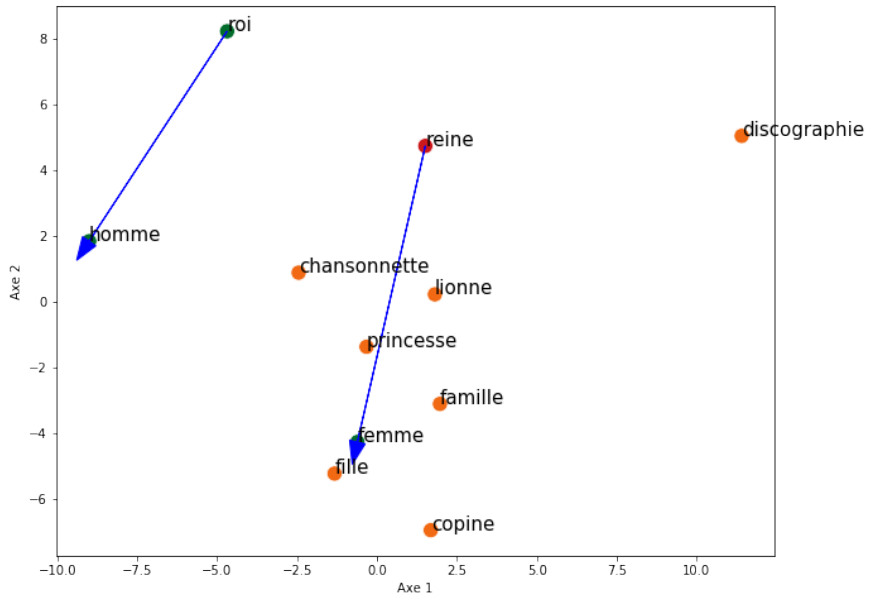

$$\overrightarrow{Roi} - \overrightarrow{Homme} + \overrightarrow{Femme} = ?$$

➔ Réduction de dimension des vecteurs-mots et (parfois) opérations sur les mots **convaincants**

Sommaire

Prédire le sentiment d'un tweet

- **Idée** : associer à chaque tweet un sentiment :
  - 1 s'il est positif
  - 0 s'il est négatif.

- base de 23 000 tweets annotés sur les transports urbains
  - **base d'entraînement** : 16 000 tweets
  - **base de test** : 7 000 tweets

- 2 approches :
  - **Modèle lexical** : utiliser l'information des tweets labelisés pour construire un sentiment moyen par mot.
  - **Modèle logit** : utiliser les *word-embeddings* comme prédicteurs d'une régression logistique.

Modèle lexical : sentiment moyen des mots

Le sentiment prédit d'un tweet t composé de n mots sera :

$$S_{1,\gamma}(t) = \mathbb{1}\left\{\frac{1}{n}\sum_{i=1}^{n}\alpha_i \geq \gamma\right\} \qquad \in \{0,1\}$$

- $\gamma \in [-1,1]$ un seuil fixé ;
- $\alpha_i = \frac{nb_+(i)-nb_-(i)}{nb_+(i)+nb_-(i)} \in [-1,1]$ sentiment moyen du mot i calculé à partir du nombre de tweets positifs ($nb_+(i)$) et négatifs ($nb_-(i)$) dans lesquels il apparaît.

➔ *Accuracy*[1] $= 89{,}1\ \%$ ($\gamma^* = -0{,}14$).

1. **Taux de tweets dont le sentiment est bien prédit.**

Modèle logit : prédiction grâce aux *word-embeddings*

Le sentiment prédit d'un tweet t sera :

$$S_{2,\gamma}(t) = \mathbb{1}\{\mathbb{P}(Y_i = 1|X_i) \geq \gamma\} \qquad \in \{0, 1\}$$

Avec :

$$Y_i = \mathbb{1}\left\{\sum_{i=1}^{n} \beta_i X_{i,j} + \varepsilon_i \geq 0\right\} \quad \mathbb{P}(Y_i = 1|X_i) = F_\varepsilon\left(\sum_{i=1}^{n} \beta_i X_{i,j}\right)$$

- Y_i le sentiment du tweet i ;
- $X_{i,1}, \ldots, X_{i,n}$ les coordonnées de la *sentence-embedding* du tweet i ;
- ε_i le résidu de notre modèle, de fonction de répartition F_ε qui vaudra $F_\varepsilon(x) = \frac{1}{1+e^{-x}}$ dans le cas d'un modèle logit et $F_\varepsilon(x) = \Phi(x)$ (fonction de répartition d'une loi $\mathcal{N}(0, 1)$) dans le cas d'un modèle probit.

Spécifications du modèle logit

Plusieurs points à traiter :

- Doit-on inclure les *stop-words* ? OUI
- Comment traiter les mots inconnus ? AFFECTER LE VECTEUR-MOT LOWFREQUENCY
- Modèle probit ou logit ? LOGIT

➔ *Accuracy* = 69,8 % ($\gamma^* \simeq 0,5$).

Limites des modèles utilisés

Modèle lexical ici meilleur que le modèle logit car . . .

1. Davantage de mots inconnus dans le modèle logit (36,2 % du vocabulaire contre 13,2 % dans le modèle lexical)

Limites des modèles utilisés

Modèle lexical ici meilleur que le modèle logit car . . .

1. Davantage de mots inconnus dans le modèle logit (36,2 % du vocabulaire contre 13,2 % dans le modèle lexical)
2. Le processus d'annotation utilisé pour les tweets sur les transports urbains reproduit en partie par le modèle lexical (?)

Limites des modèles utilisés

Modèle lexical ici meilleur que le modèle logit car . . .

1. Davantage de mots inconnus dans le modèle logit (36,2 % du vocabulaire contre 13,2 % dans le modèle lexical)
2. Le processus d'annotation utilisé pour les tweets sur les transports urbains reproduit en partie par le modèle lexical (?)
3. Le *domain shift*

Limites des modèles utilisés

Modèle lexical ici meilleur que le modèle logit car . . .

1. Davantage de mots inconnus dans le modèle logit (36,2 % du vocabulaire contre 13,2 % dans le modèle lexical)
2. Le processus d'annotation utilisé pour les tweets sur les transports urbains reproduit en partie par le modèle lexical (?)
3. Le *domain shift*

➔ Utilisation d'une nouvelle base de test pour neutraliser certains de ces effets

Modèle logit alors meilleur que le modèle lexical
(*Accuracy* de 61,9 % contre 55,9 %).

Sentiments des tweets et enquête Camme

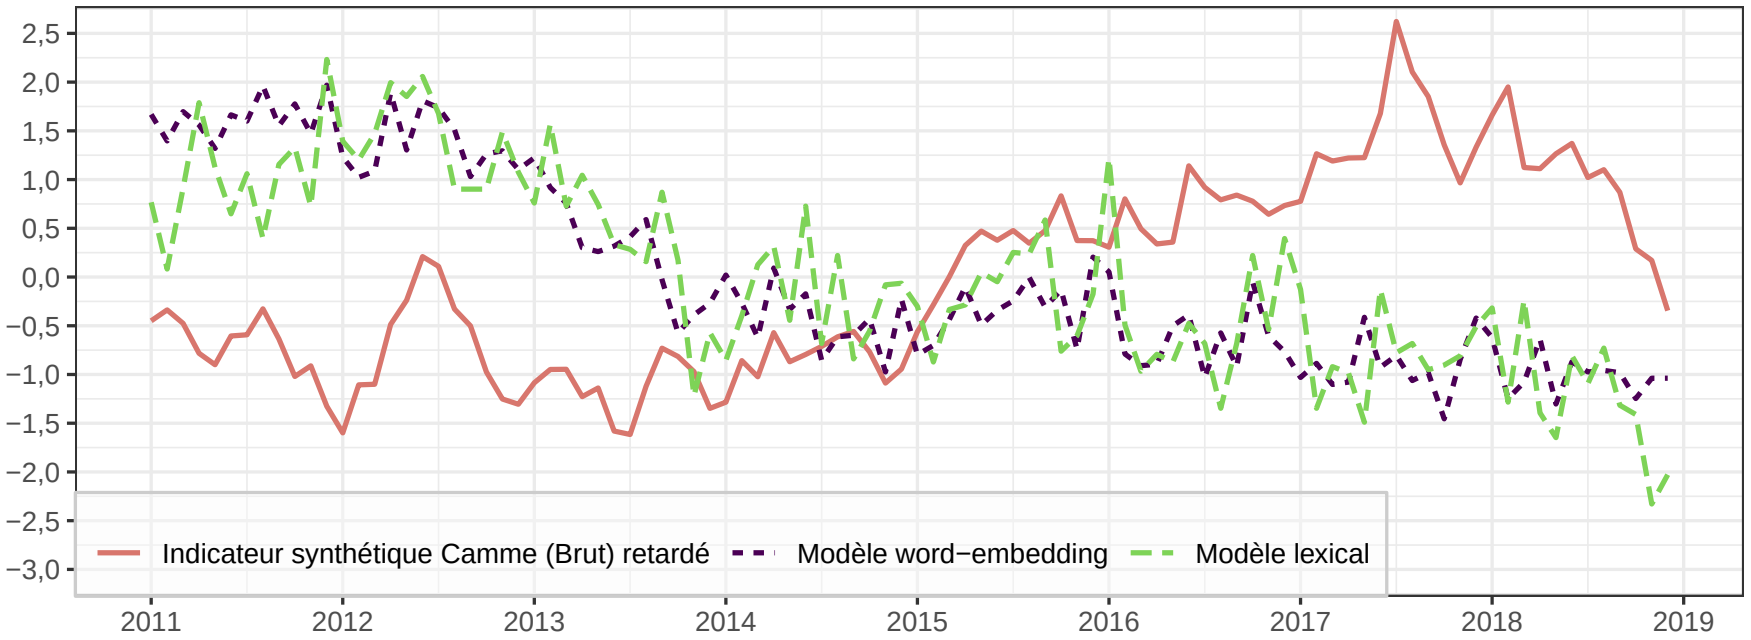

Sentiments des tweets et enquête Camme

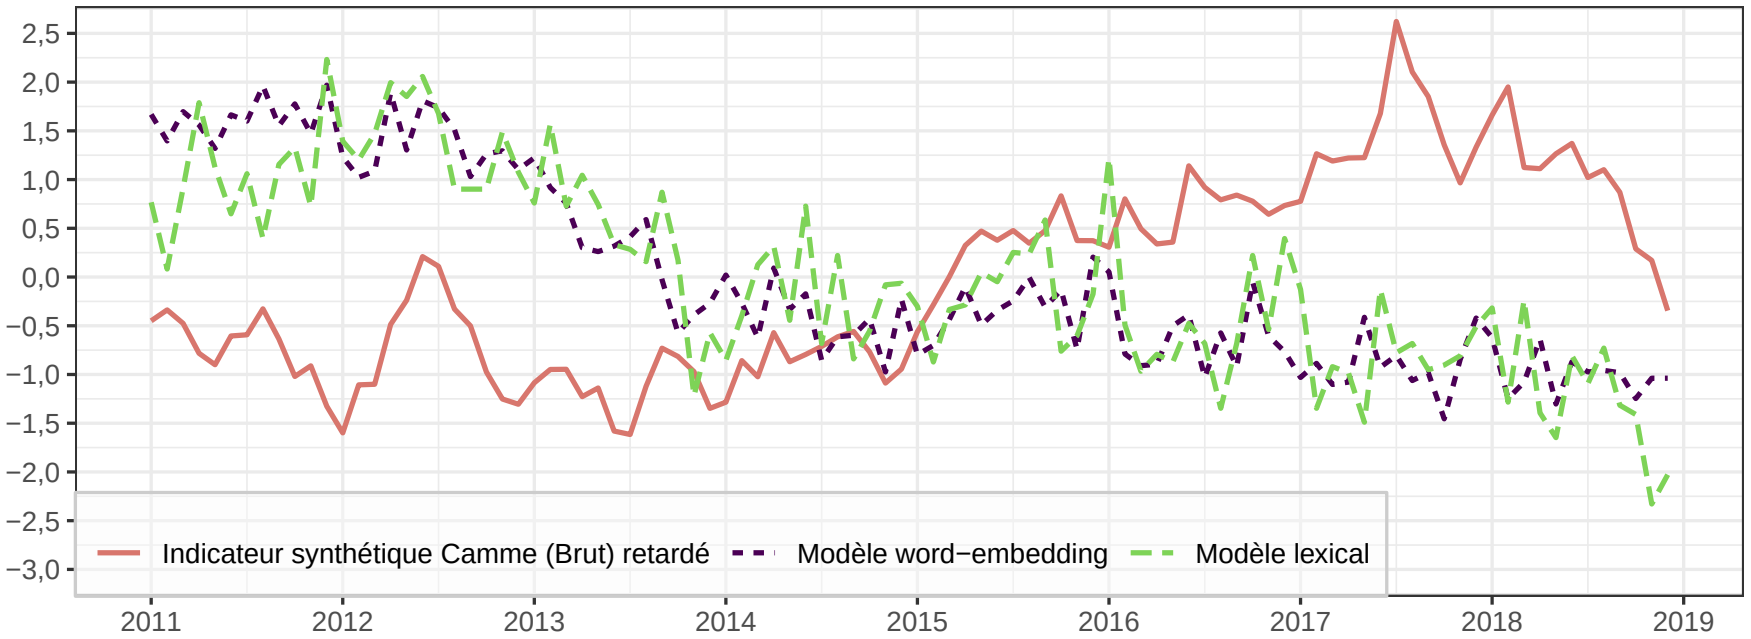

- Indicateurs relativement éloignés de l'enquête Camme
- Similarité (DTW) avec indicateur Camme plus proche avec modèle lexical que modèle word-embedding

Sentiments des tweets et enquête Camme

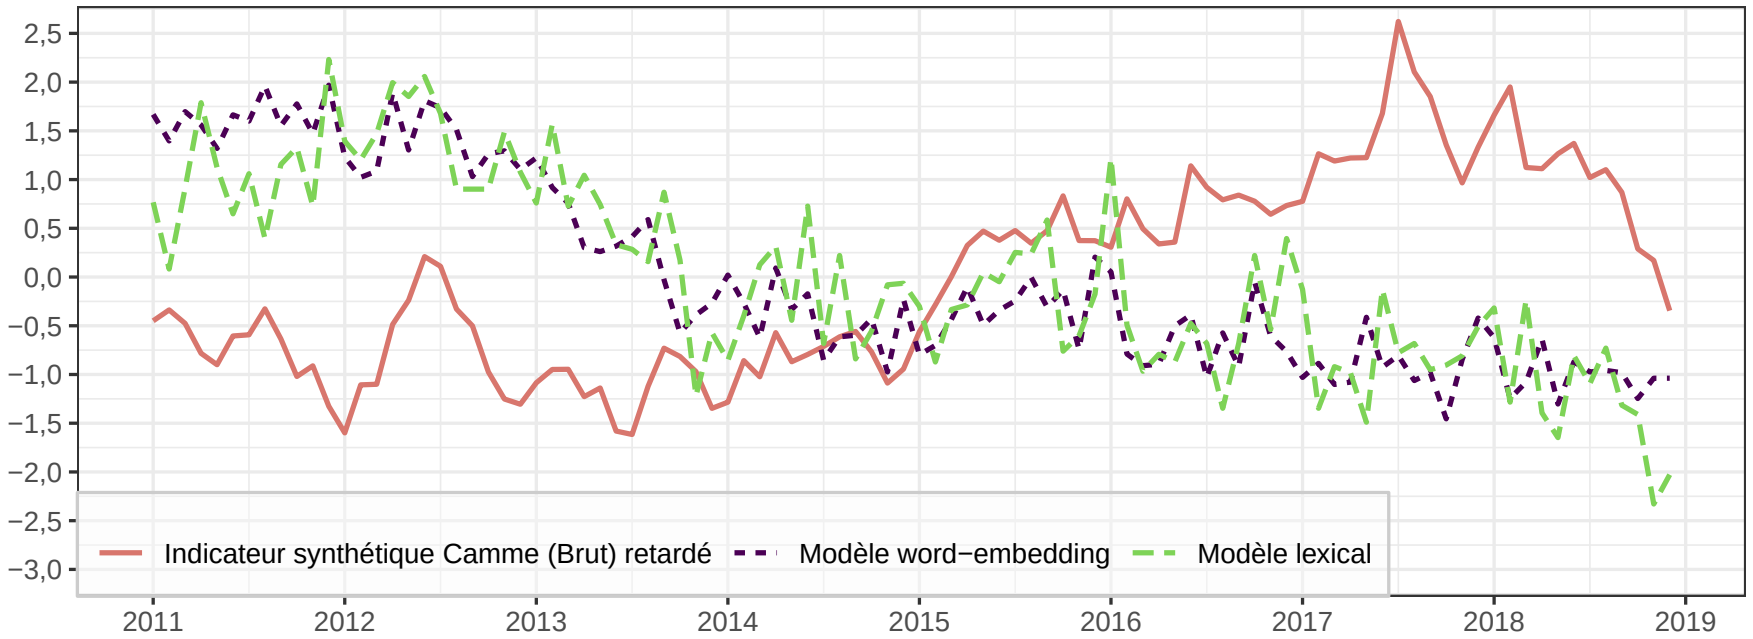

- Indicateurs relativement éloignés de l'enquête Camme
- Similarité (DTW) avec indicateur Camme plus proche avec modèle lexical que modèle word-embedding

- Modèle word-embedding utile pour prévoir indicateur Camme (causalité de Granger) $\neq$ modèle lexical
- Modèle indicateur **avancé** des sentiments des ménages

Sommaire

Conclusion (1/2)

- *Word2vec* . . .
  - capture **très bien** la sémantique des mots dans un texte
  - prédit **assez bien** le sentiment d'une phrase
  - est **potentiellement utile** pour prédire l'indicateur synthétique de confiance des ménages de l'Insee . . .
  - . . .mais demeure **très différent** de cet indicateur (en évolution)

Conclusion (1/2)

- *Word2vec* . . .
  - capture **très bien** la sémantique des mots dans un texte
  - prédit **assez bien** le sentiment d'une phrase
  - est **potentiellement utile** pour prédire l'indicateur synthétique de confiance des ménages de l'Insee . . .
  - . . .mais demeure **très différent** de cet indicateur (en évolution)

- Pourquoi très différent ?
  - Principalement en raison de leurs **différentes philosophies** (sujets spécifiques de Camme VS positivité ou non des tweets pour notre indice) . . .
  - . . .{} mais aussi à cause des **limites de la base d'entraînement** de tweets annotés (domain-shift, processus d'annotation, mots inconnus)

Conclusion (2/2)

Pistes d'amélioration ?

- disposer d'une **base de tweets traitant de sujets divers, et bien annotés** (gradation de sentiments, modèles de type BERT, analyse approfondie du contenu et des auteurs des tweets . . .)
- améliorer le **prétraitement des tweets** (orthographe des mots, modèle à séquences d'unités de sous-mots type *fasttext* . . .)
- utiliser des **modèles d'analyse de sentiment plus élaborés** (type réseaux de neurones récurrents)

Merci pour votre attention

ARKEnsae/TweetEmbedding

Rapport du projet